

译文 | 语言学数据引用中的奥斯汀原则

语言学微刊 3月18日

译者言

目前国内部分语言学著作对数据引用没有自觉意识。在对待他人数据上：

(1) 不引用。文中出现了数据，但来源不明，我们不知道这些数据是来自其它著作、语料库还是自己整理的；文中在阐述基于数据得出的观点时没有引用；有些著作虽有说明，但缺少规范的引用格式，比如未把语料库列入参考文献，这样我们也就无法知道语料库开发者等确切信息。

(2) 引用不完整。比如没有提及谁贡献了数据以及如何做出贡献，没有提供链接或其他获取途径，没有说明引用的时间、版本等。

在对待自己的数据上：

(3) 不公开。有些数据应该通过附录或其他途径公开，有的期刊论文限于篇幅未列附录，但也没有通过其他途径公开；有的文章虽有附录，但比较简略，没有通过其他途径公开完整数据。

(4) 不透明。处理和分析数据的方法不够透明，其他学者无法重复其处理和分析的方法。

我们注意到，在国际语言学界，“语言学中数据引用的奥斯汀原则”（The Austin Principles of Data Citation in Linguistics）已较为通行。该原则是美国国家科学基金项目“Developing Standards for Data Citation and Attribution for Reproducible Research in Linguistics”（项目编号为NSF SMA-1447886，主要成员包括Andrea L. Berez-Kroeker、Gary Holton、Susan Smythe Kung和Peter Pulsifer）的成果之一，因在得克萨斯州首府奥斯汀举办的2017年度美国语言学年会上进行了小组讨论而得名，后不断吸取各种反馈意见而形成如今的书面版本。该原则由“语言学数据兴趣小组”（Linguistics Data Interest Group，简称LDIG）基于“FORCE11数据引用原则共同宣言”（The FORCE11 Joint Declaration of Data Citation Principles）*撰写，其主席为Helene N. Andreassen（挪威特罗姆瑟大学）、Andrea Berez-Kroeker（夏威夷大学马诺阿分校）和Lauren Gawne（拉筹伯大学）。**我们把该原则翻译为中文，以飨读者，希望国内语言学界在数据引用上更加规范。

翻译由杨旭和吕佩完成，《语言学微刊》编辑部提出了详尽修改意见，特此致谢！

* “FORCE11”源于2011年8月在德国达格斯图尔举办的FORC研讨会，是一个促使研究数据成为学术记录组成部分的国际组织，由来自不同学科的学者、图书馆员、档案管理员、出版商和研究资助者组成。该组织于2014年发布了“FORCE11数据引用原则共同宣言”，提出了数据引用的八个原则：重要性、荣誉和署名、证据、唯一标识、可获取、永久不变、具体性和可验性、互通性和灵活性。“奥斯汀原则”正是在此基础上提出的。

** 更多信息可参官方网站：

<https://site.uit.no/linguisticsdatacitation/>

语言学中数据引用的奥斯汀原则

(1.0版本)

The Austin Principles of Data Citation in
Linguistics

语言学数据兴趣小组

2018年3月3日

01 引言

数据对于实证语言学研究来说至关重要。语言数据的形式多样，可以通过多种方法收集和处理。数据引用是对数据在研究中核心地位的承认，有助于验证某些观点的真伪，还有助于把数据用于其他研究。

“FORCE11数据引用原则共同宣言”宣称：“完整且可复制的学术研究有赖于可靠且可得的数据。要在理论上和实践上做到这一点，学术实践和持续的学术记录必须认识到数据的重要性。换句话说，数据应被视为正当合理和可被引用的研究成果。引用数据应该像引用其他证据或出处一样，被视为良好的学术行为，且是学术生态支持数据再利用的应有之义。”

“FORCE11数据引用原则共同宣言”覆盖的范围很广，尽可能多地囊括了来自多个学科的数据类型。而“语言学中数据引用的奥斯汀原则”则对FORCE11文件做了解读，专门用来解决语言数据问题。我们制定这些指导原则的目的是，促使语言学家在处理数据时尽可能做到易于获取和公开透明。一些语言学分支学科已有针对数据引用的具体原则，在这种情况下，奥斯汀原则可以予以补充，以使其做到尽善尽美。

02 原则

“语言学中数据引用的奥斯汀原则”包括引用目的、功能和署名。数据引用必须做到人类能够理解，机器能够执行——奥斯汀原则对此均有体现。当然，这些原则并非面面俱到。此外，考虑到引用在不同群体之间存在差异，以及技术随时发生更新，我们不会提出非常具体的意见，而是鼓励相关群体研发出适合自己的做法和工具，只要能够体现出这些原则足矣。

以下排序不分主次，只是为了方便理解。引号内文字来自FORCE11文件。

1 重要性 (Importance)

“数据应被视为正当合理和可被引用的研究成果。我们应该像重视其他研究成果（如出版物）的引用一样，重视数据的引用。”

语言数据不仅是学术成果的记录，而且也是文化传承、社会进化和人类潜能的记录。为此，语言分析所倚赖的数据至关重要，而且理应如此。语言数据要可被引用，而且要被注明引用，我们应该像重视其他研究成果（如出版物）的引用一样重视数据引用。

2 荣誉和署名 (Credit and Attribution)

“数据引用应该有助于为所有的数据贡献者提供学术荣誉，以及给予规范和合法之署名；当然也要意识到，单一的署名方式并不一定适用于所有的数据。”

在合适的情况下，语言学数据引用需要告知读者，谁为数据做出贡献以及如何做出贡献。要做到这一点，一种办法是引用时列出所有贡献者及其担任的角色，一种办法使用能够链接到有关贡献者及其角色之原始数据的引用。

3 证据 (Evidence)

“在学术文献中，只要某个观点依赖于数据，就要对相应数据有所引用。”

语言学家在发表观点时，如果是基于相关的数据，就一定要引用。为了方便大家引用数据，应该把数据存储到人们可以获取的地方，最好是数据档案或其他可信任的资源库。为了把数据和观点之间的关系解释清楚，作者应该保证数据的收集和处理方法透明，可以采用链接到元数据或文中说明部分的方式来做到这一点。

4 唯一标识 (Unique Identification)

“数据引用应该做到标识法永久不变，且保证标识法机器可执行、全球唯一以及得到群体之广泛使用。”

在选择资源库或其他平台存储数据或导向数据的方式时，语言学家应该寻找能以永久标识符（Persistent Identifier，简称PID）进行标识的服务。对于数字数据而言，这些服务包括数字对象唯一标识符（Digital Object Identifiers，简称DOI）和句柄系统（Handles）。

5 可获取（Access）

“数据引用应该方便读者获取数据和与之相关的元数据、文档、代码及其他资料，这对人类和机器有效使用所引数据很有必要。”

为了其他研究再利用，语言数据应尽可能开放；但有时为了尊重相关民族、法律和说话者群体的限制，也要在必要时封闭**。

6 永久不变（Persistence）

“唯一标识符、描述数据及其处理方式的元数据应该保持永久不变，即便所描述的数据已经过期，也要做到这一点。”

语言学家在选择资源库或存储库时，应该确认其条款中写明数据、元数据和标识符保持永久不变。

7 具体性和可验性（Specificity and Verifiability）

“数据引用应该方便读者能够识别、获取和验证支持相关论述的具体数据。引用或引用元数据应该包括有关出处和是否变化的信息，读者通过这些信息可以确定之后获取的数据，在具体的时间片（timeslice）、版本和/或数据的详略上是否和原先引用的数据一致。”

数据引用应该确保读者能够在大量数据中定位到支持某观点的具体数据和数据子集，数据使用如果要做到精细和明确，就应该使用系统的数据标识法。

很多数据集（data sets）不是静态的，而是研究者随时在添加新的数据。为此，引用应该说明版本。

8 互通性和灵活性 (Interoperability and Flexibility)

“数据引用的方法应该足够灵活，能够包括不同群体的不同做法，但是不可造成不同群体之间不可互通。”

在解决各种各样的问题时，语言学家要和各种各样的数据打交道。语言学的引用标准要满足研究群体的需要，也要遵循上述原则。

我们鼓励语言学出版者通过开发数据引用格式来使数据引用变得更加容易，也鼓励基于这个文件开发出更加明确的数据条款。

* Data Citation Synthesis Group: Joint Declaration of Data Citation Principles. Martone M. (ed.) San Diego CA: FORCE11; 2014
<https://doi.org/10.25490/a97f-egykh>

** 尽可能开放和在必要时封闭是欧盟委员会在其《地平线2020方案 (Horizon 2020 Programme) 》所采取的办法。

03 如何使用奥斯汀原则

本文依据Creative Commons Attribution 4.0 International License*进行授权。



* <https://creativecommons.org/licenses/by/4.0/>

04 如何引用奥斯汀原则

Berez-Kroeker, Andrea L., Helene N. Andreassen, Lauren Gawne, Gary Holton, Susan Smythe Kung, Peter Pulsifer, Lauren B. Collister, The Data Citation and Attribution in Linguistics Group, & the Linguistics Data Interest Group. 2018. The Austin Principles of Data Citation in Linguistics. Version 1.0. <https://site.uit.no/linguisticsdatacitation/austinprinciples/> Accessed [date]

BibTeX citation:

@Misc{AustinPrinciples:2018,

author = "Andrea L. Berez-Kroeker and Helene N. Andreassen and Lauren Gawne and Gary Holton and Susan Smythe Kung and Peter Pulsifer and Lauren B. Collister and {the Data Citation and Attribution in Linguistics Group} and {the Linguistics Data Interest Group}",
title = "The {Austin} Principles of Data Citation in Linguistics",
year = 2018,
note = "Version 1.0",
url = "https://site.uit.no/linguisticsdatacitation/austinprinciples"

05 如何评论奥斯汀原则

所有与之相关的评论、问题和反馈我们都很欢迎。我们鼓励大家在“语言学数据兴趣小组”网页的评论区公开发表意见：

<https://www.rd-alliance.org/groups/linguistics-data-ig>。

如果您想与我们直接联系，可以发送邮件至：

lingdata@hawaii.edu。

(杨旭、吕佩译)

原文来自：

<https://site.uit.no/linguisticsdatacitation/austinprinciples/>

联系译者：

杨旭，武汉大学文学院讲师，研究方向为语法理论、现代汉语语法。Email: yanghsu@whu.edu.cn

吕佩，山西师范大学文学院讲师，研究方向为现代汉语语法。Email: lvpei123123@163.com

排版：清源