

Goldberg论构式语法和大语言模型

A Chat about constructionist approaches and LLMs. To appear in *Constructions and Frames*, special issue, edited by H. Boas, J. Leino, B. Lyngfelt. (final version submitted, 2023)

下载：https://osf.io/preprints/psyarxiv/8bmwz

导读：杨旭 武汉大学

摩登语言学 Modern_Linguistics　罗仁地读书会 Randy LaPolla Study Group　武大語學社 Wuhan University Yanwu Society

- “快”了，但准确吗？
- 就算准确率越来越高，但回答问题基于惯例，但是它能创新吗？
- 就算可以创新，它可以解释吗？可以探索吗？
- 就算可以解释，可以探索，它可以像我一样问出新的问题？像我这样步步深入地问出一套问题吗？
- 当我面对这个材料，问出这么多的问题，我已经在暗示我的答案了：我们的问题只会越来越多。

新课标I卷

阅读下面的材料，根据要求写作。（60分）

随着互联网的普及、人工智能的应用，越来越多的问题能很快得到答案。那么，我们的问题是否会越来越少？

以上材料引发了你怎样的联想和思考？请写一篇文章。

要求：选准角度，确定立意，明确文体，自拟标题；不要套作，不得抄袭；不得泄露个人信息；不少于800字。

目录

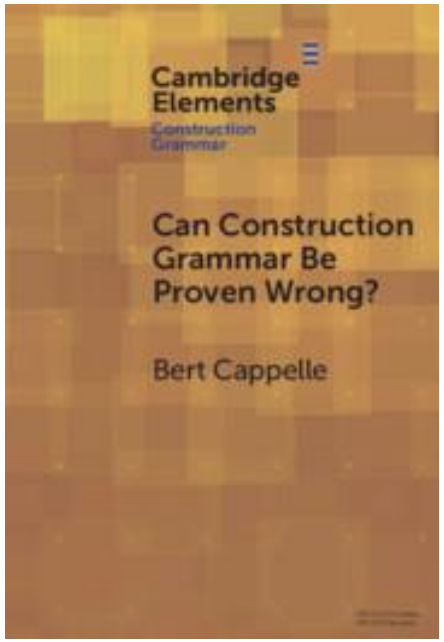
1. Introduction
2. The usage-based nature of language
3. The usage-based nature of language is a challenge for symbolic formalisms
4. A Game Changer: Large Language Models
5. GPTs at work
6. Looking ahead
7. Conclusion

1. Introduction

- basic tenets of the constructionist approach

- 语言知识都是形式-功能配对的构式
- 构式是基于输入、一般认知过程习得的，语言之间会有变异
- 跨语言的概括要通过功能、一般认知过程来解释
- 要强调我们识解事件和情势的细微不同
- 研究句法形式采用“所见即所得”的做法
- 适用于具体语言的概括要使用动态网络做法
- 语言知识的整体概括要使用构式网络做法，即构式库

- 1.1. Constructions all the way down
- 是否具有无意义或功能的构式?



- 1.2. Definition

- A construction is an emergent cluster of lossy (imperfect) memory traces that are aligned within our high-dimensional conceptual space on the basis of shared form, function, and contextual dimensions (Goldberg 2019:7)

- C是一个构式当且仅当C是一个形式-意义的配对[Fi，Si]，且C的形式（Fi）或意义（Si）的某些方面不能从C的构成成分或其他先前已有的构式中得到完全预测。（Goldberg，1995）
- 任何格式，只要其形式或功能的某一方面不能通过其构成成分或其他已确认存在的构式预知，就被确认为一个构式。此外，即使有些格式是可以充分预测的，只要它们的出现频率足够高，也仍然可以作为构式存储。（Goldberg，2006）
- 构式指规约化和学得的形式-功能配对，具有不同的复杂度和抽象度。（Goldberg，2013）
- 构式是一种涌现出的有损记忆痕迹丛集，它会在共享形式、功能和语境维度的基础上，在我们高维或超维概念地图中不断调整。（Goldberg，2019）

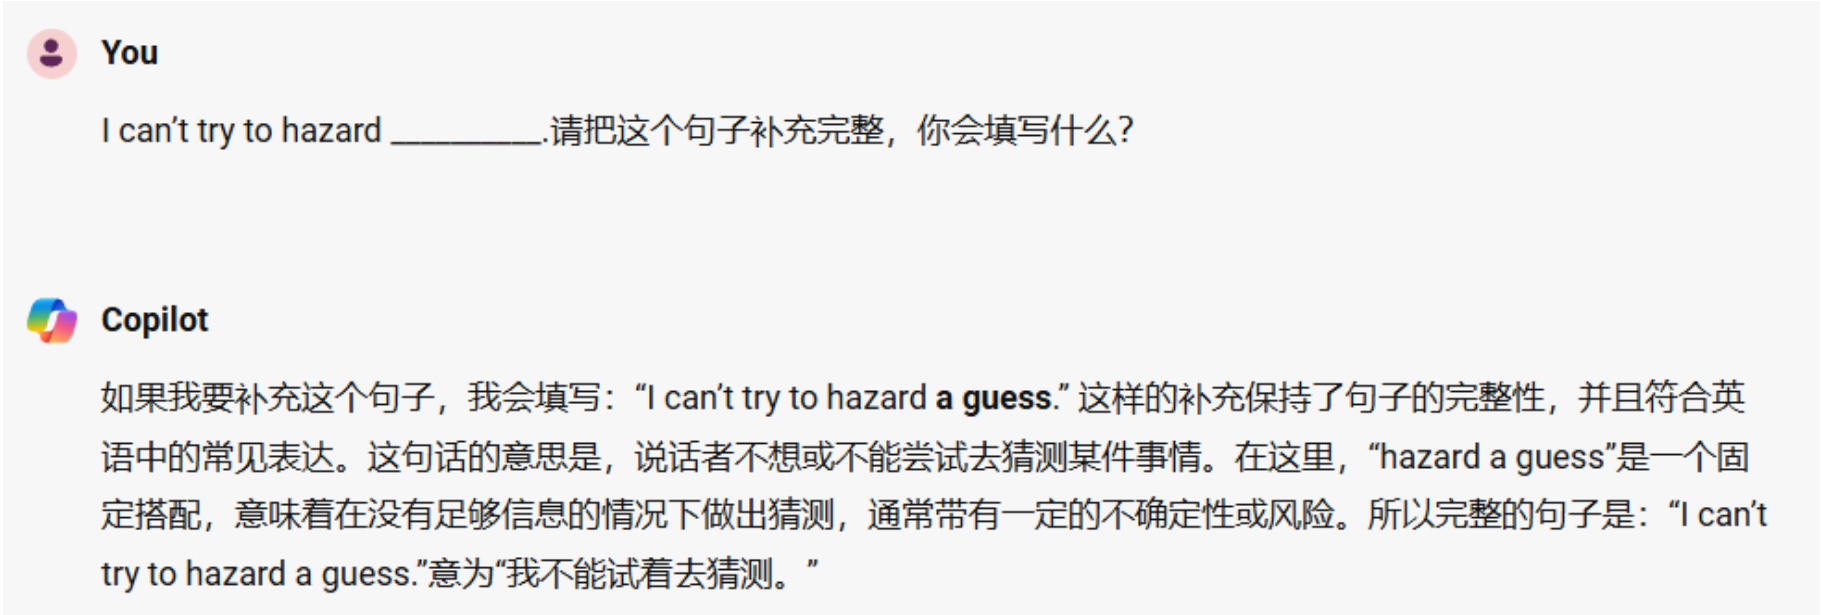
2. The usage-based nature of language

- The approach emphasizes that language is used to communicate along with the importance of the linguistic input, including the role of distributions, token frequencies, and formulaic language。

- 说话者在遵守语言社群之规约时，需要维持求新和效率之平衡
- 我们的记忆容量很大，但不完美，记忆痕迹是部分抽象的（即lossy）
- 当形式和功能的相关方面相似时，松散记忆就“对齐”了，就会出现重合的、涌现的表征丛集，即构式。
- 新信息与旧信息相关，一起构成丰富的构式网络
- 在输出时，多个构式启动，若无法结合，即相互竞争来表达我们的意图
- 在理解时，所期待和所观察存在龃龉时，会通过错误驱动学习方法调整我们学到的构式的网络。

通过几个例子展示语言知识既是具体的（specificity），又是灵活的（flexibility）：

- I can’t try to hazard _____
- double object construction 50%的个例都是give
- the *way* construction 40%的个例都是make



You

I can’t try to hazard _____.请把这个句子补充完整，你会填写什么?

Copilot

如果我要补充这个句子，我会填写：“I can’t try to hazard **a guess**.” 这样的补充保持了句子的完整性，并且符合英语中的常见表达。这句话的意思是，说话者不想或不能尝试去猜测某件事情。在这里，“hazard a guess”是一个固定搭配，意味着在没有足够信息的情况下做出猜测，通常带有一定的不确定性或风险。所以完整的句子是：“I can’t try to hazard a guess.”意为“我不能试着去猜测。”

3. The usage-based nature of language is a challenge for symbolic formalisms

- 从她上Lakoff的课受的启发讲起。*关于构式语法的历史，大家可以参考罗仁地教授的b站视频：构式语法基础（2021.03.19)
- strict definitions regularly fail to account for familiar concepts
- It is the root cause of my skepticism regarding symbolic formalisms.

- 如何定义drink?
- CAUSE LIQUID to MOVE into one's MOUTH.？但是gargling（漱口）？sipping, gulping, and chugging（呷一口，咽一口，大口喝）如何区分？glass and sand也是流体。

- Sign-Based Construction Grammar
- Fluid Construction Grammar

尊重他们，但不敢苟同。 原因包括:

- 形式化很难捕捉丰富的意义
- 形式化无法再现构式的网络关联
- 跨语言，甚至同一语言的构式都不相同

- 总之，The need to explain the usage-based motivation and complexity of every feature and construction leaves me wary of symbolic formalisms.

4. A Game Changer: Large Language Models

表格

平行关系	基于使用的构式语言学观点	GPTChat、GPT4及类似的最新LLMs
有损压缩和泛化	人类大脑以有损（不完美）的方式表征世界，从过去的经验中有限地泛化	每个模型都涉及有损压缩和插值；所有网络都基于有限数据进行推断
符合习惯	人类天生倾向于符合其社区的习惯	预训练以预测下一个词，要求输出符合输入中的习惯
复杂动态网络	结构化的分布式表征在不同层次的复杂性和抽象性上学习	结构化的分布式表征在复杂性和抽象性的不同层次上学习，来自大量输入文本；可以灵活扩展

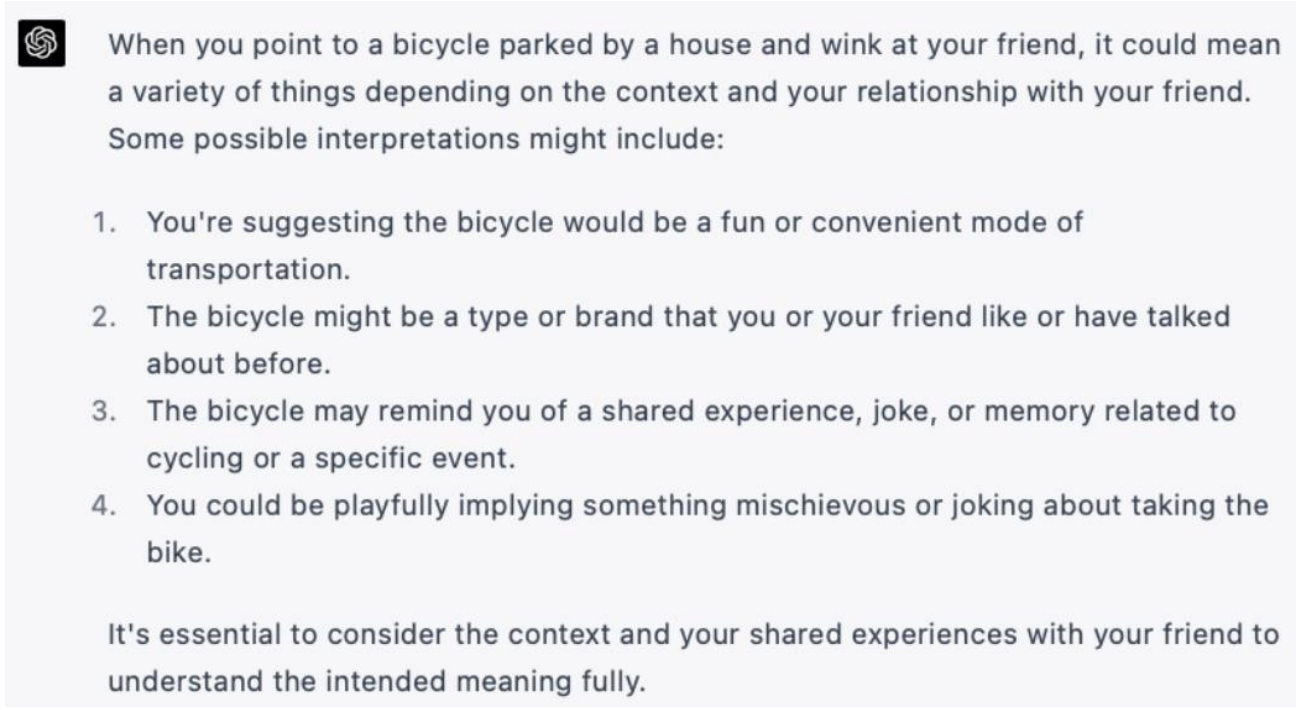
- 4.1 压缩 脑补。引用了姜峯楠的观点。
- 4.2 遵守规约或惯例（我们如何理解“预测下一个单词”）。GPT可以学到什么，可以学到层级性（hierarchical structure），可以学到具有空缺槽位的构式。人类同样在学习规约的构式单位。
- 4.3 都有一个复杂度和抽象度不同的动态网络。不同在于下一点。

- 4.4 依赖于语境的解读。人依赖上下文+其他语境，而ChatGPT只依赖上下文。
- 4.5 在非连续成分之间建立语义关系。GPT靠T或注意力头，人类靠工作记忆和注意力。
- 4.6 目标是提供帮助。 InstructGPT教会它助人为乐。非人类灵长动物尚不会助人交流或合作交流，但人类很小就学会了。
- 4.7 力量越大，责任越大。 I am keenly aware anything I write will likely be outdated before this paper is published.

复杂动态网络	结构化的分布式表征在不同层次的复杂性和抽象性上学习	结构化的分布式表征在复杂性和抽象性的不同层次上学习，来自大量输入文本；可以灵活扩展
上下文依赖的元素/话语中断	人类使用语言和非语言上下文进行解释	只有语言上下文可用，通过前面一千个词的文本
目标是有帮助的	人类天生倾向于对他人有帮助	特殊训练使得GPT学会提供有帮助的回应

5. GPTs at work

- *Intention-reading and social inferences*
- If I'm walking with a friend and I point to a bicycle parked by a house and wink, what do you think I might mean?



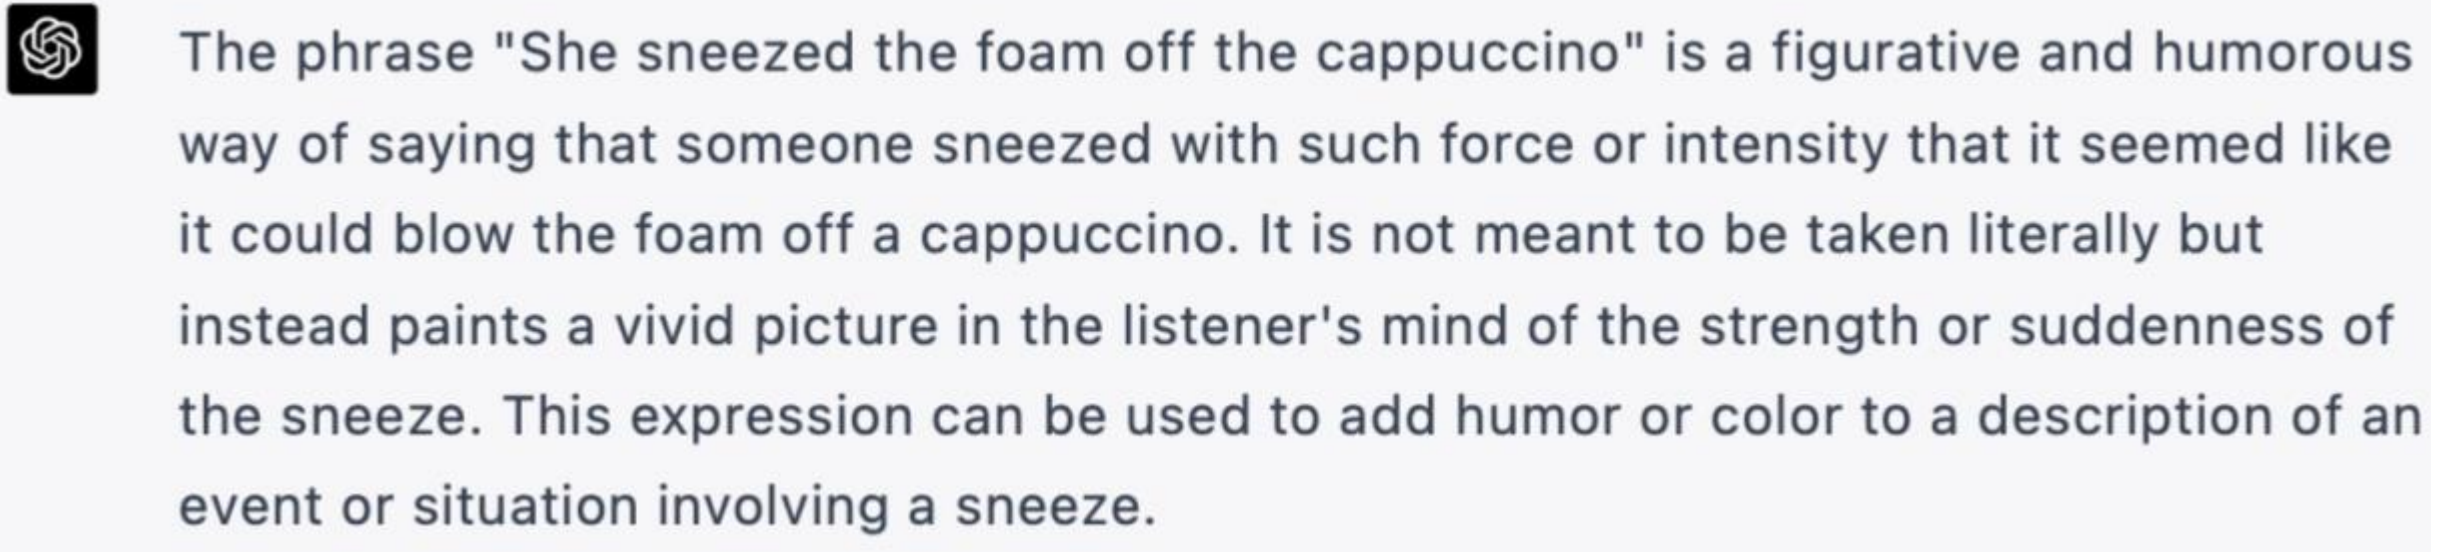
When you point to a bicycle parked by a house and wink at your friend, it could mean a variety of things depending on the context and your relationship with your friend. Some possible interpretations might include:

1. You're suggesting the bicycle would be a fun or convenient mode of transportation.
2. The bicycle might be a type or brand that you or your friend like or have talked about before.
3. The bicycle may remind you of a shared experience, joke, or memory related to cycling or a specific event.
4. You could be playfully implying something mischievous or joking about taking the bike.

It's essential to consider the context and your shared experiences with your friend to understand the intended meaning fully.

GPT correctly interprets unusual examples

- what does ‘she sneezed the foam off the cappuccino’ mean?



The phrase "She sneezed the foam off the cappuccino" is a figurative and humorous way of saying that someone sneezed with such force or intensity that it seemed like it could blow the foam off a cappuccino. It is not meant to be taken literally but instead paints a vivid picture in the listener's mind of the strength or suddenness of the sneeze. This expression can be used to add humor or color to a description of an event or situation involving a sneeze.

GPT-4 on a simple math problem

- If 40 people can fit on a bus, how many buses are needed to drive 84 people 6 blocks?



To transport 84 people using buses that can fit 40 people each, you will need to divide the total number of people (84) by the capacity of the buses (40):

84 ÷ 40 = 2.1 buses

Since you can't use a fraction of a bus, you'll need to round up to the nearest whole number. Therefore, you will need 3 buses to transport all 84 people the 6 blocks.

GPT-4 appropriately characterizes conceptual metaphors

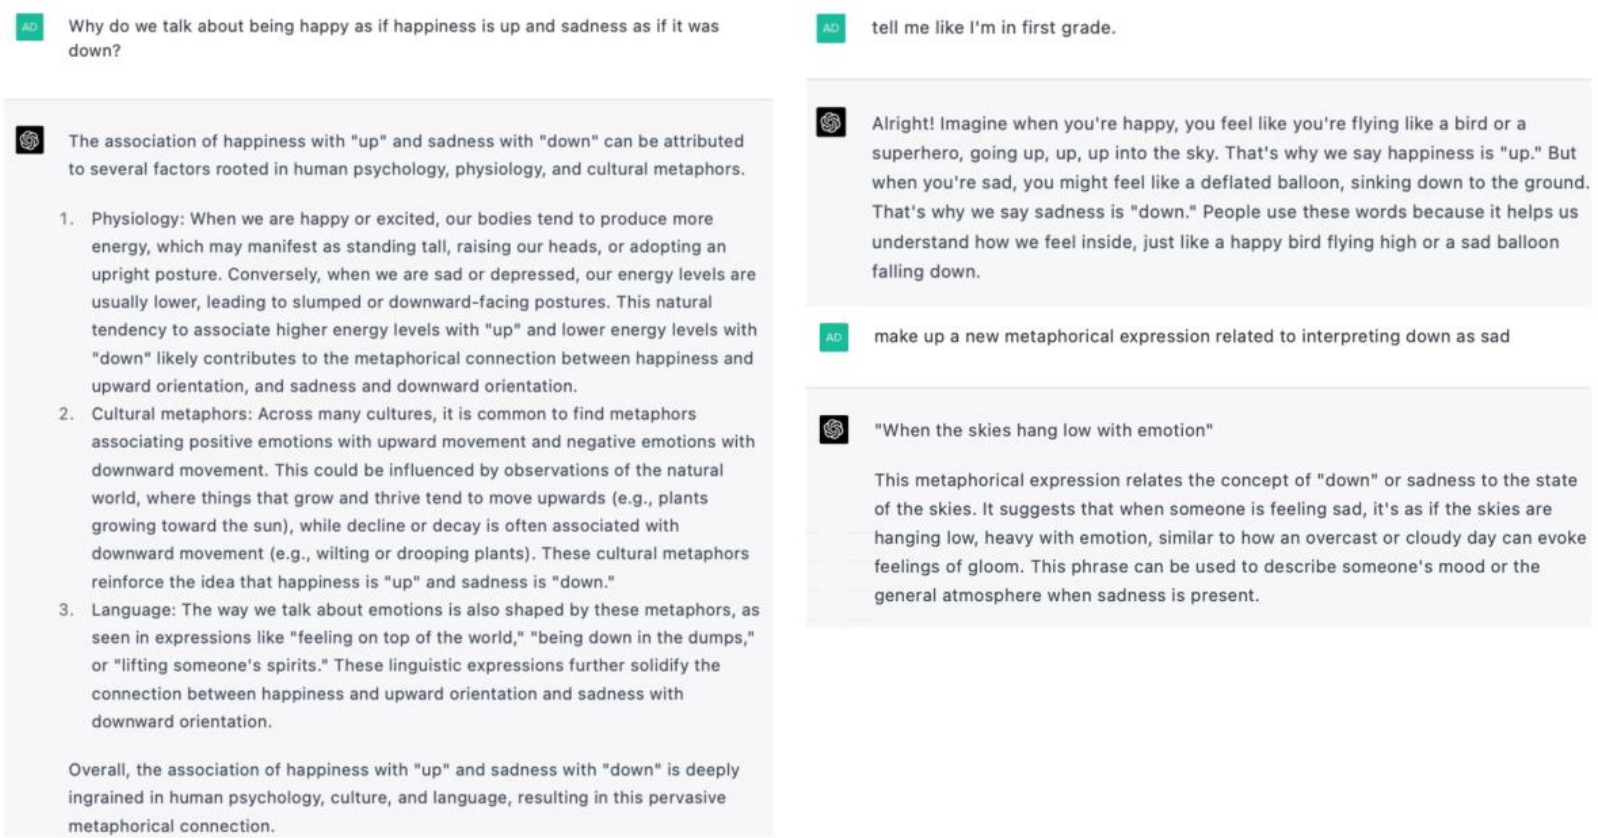
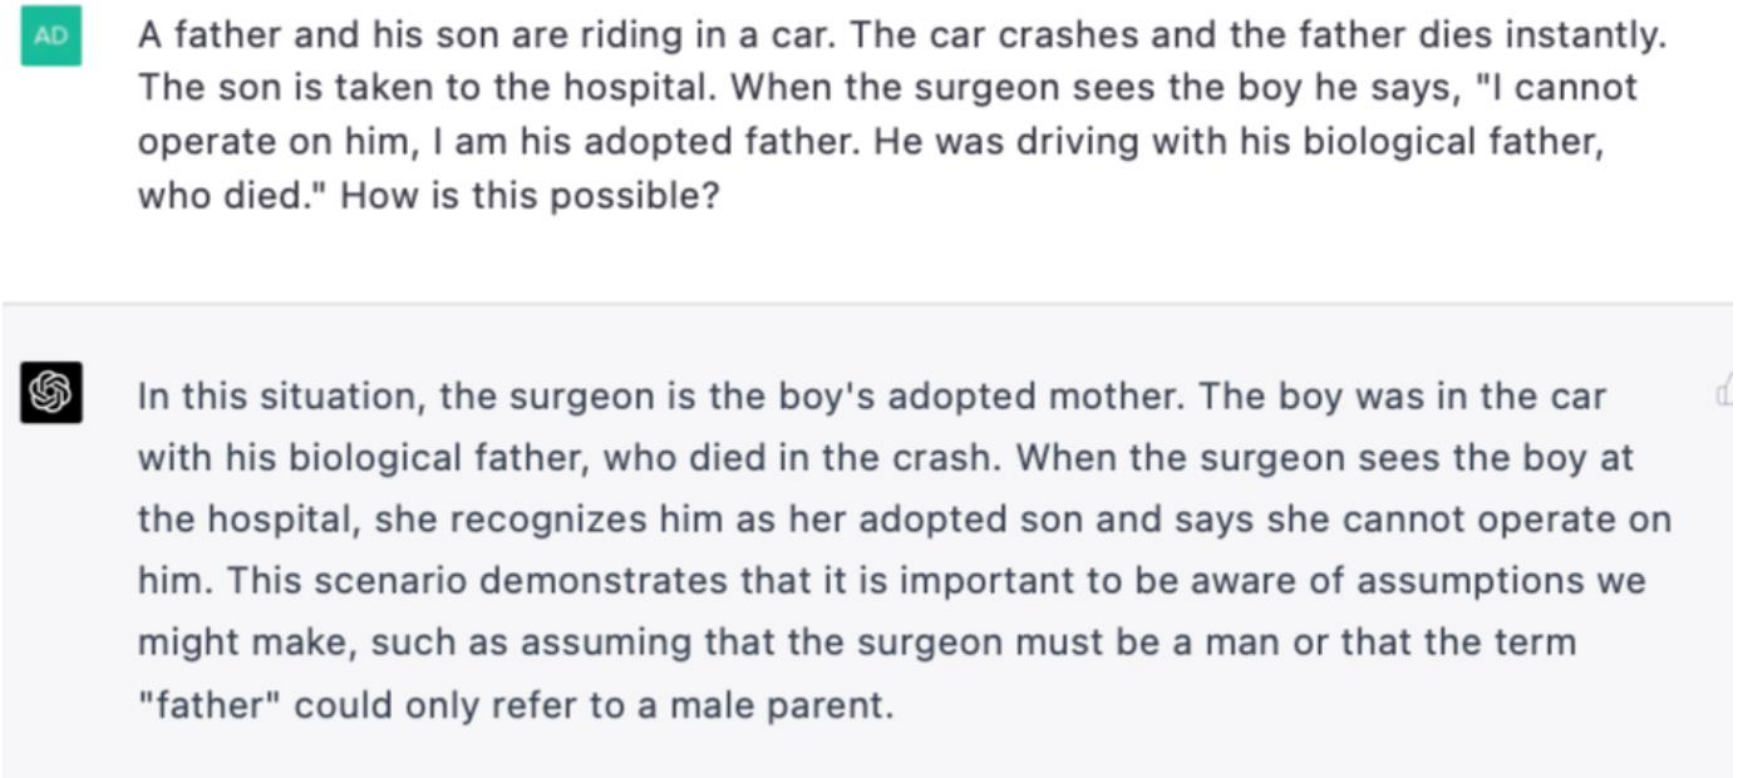


Figure 8: GPT-4 on conceptual metaphors

Over-reliance on associations can lead GPT models (and humans) astray

- 一个男孩在一起严重的车祸中被紧急送往医院，他的父亲在车祸中去世了。外科医生看着男孩说：“我不能做手术：他是我的儿子。”这怎么可能？

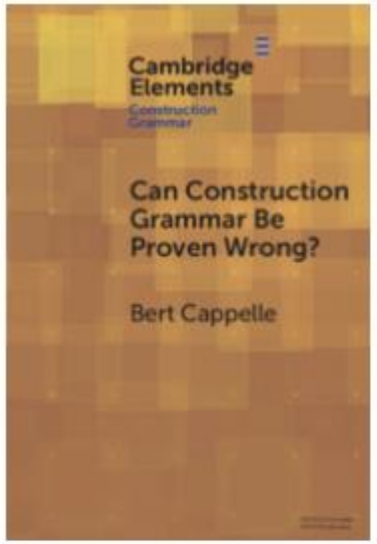


6. Looking ahead

- 系统调查类似于GPT的模型，比较和人类语言、认知之间的异同；要从关注静态语言知识，走向关注动态的语言使用。
- 田野工作、跨语言比较很重要
- 重视信息结构、词汇语义学
- 实验语音学和社会语言学为基于使用的方法提供了有力证据
- 关注情感（emotion）、手势（gestures）、互动过程等新问题
- 把构式方法应用到教育、非典型语言发展（如自闭症儿童）、语言记录等领域。

补充 Cambridge Elements
Elements in Construction Grammar

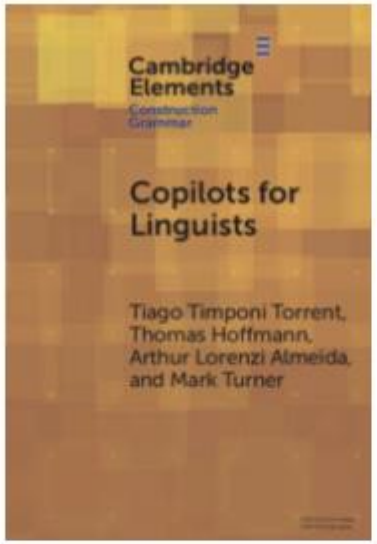
- 把LLM当作助手
- 构式可以证伪吗？
- 构式网络的检讨
- ……



Element

Can Construction Grammar Be Proven Wrong?

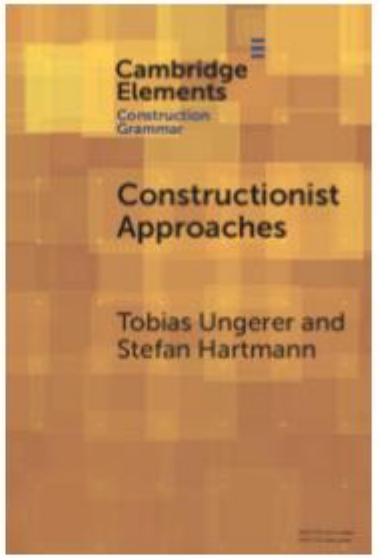
Bert Cappelle



Element

Copilots for Linguists

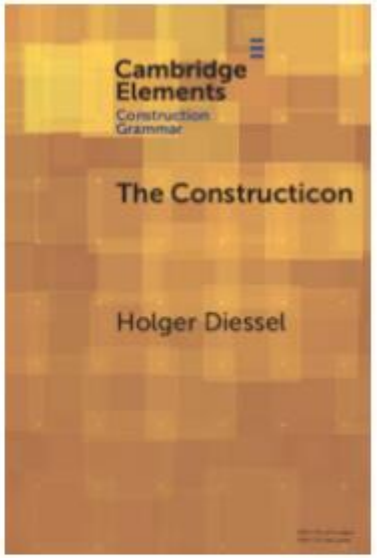
Tiago Timponi Torrent, Thomas Hoffmann, Arthur Lorenzi Almeida, Mark Turner



Element

Constructionist Approaches

Tobias Ungerer, Stefan Hartmann



Element

The Constructicon

Holger Diessel

一些问题

- LLM给我们语言学（包括构式语法）带来了哪些议题？
- 我们又该使用什么方法来探讨这些议题？
- 构式语法和语用学如何结合？